

1. Contexto de aplicación

La economía circular (EC) se define como un sistema económico que reemplaza el final de vida útil de los productos y componentes mediante la reducción, reutilización, reciclaje y recuperación de los materiales en los procesos de producción/distribución y consumo (Kirchherr, Reike, & Hekkert, 2017), de manera que se desvincula el crecimiento económico de un país en la explotación de recursos finitos, y que además busca aplicar estrategias que sean restaurativas y regenerativas, con lo cual los recursos puedan integrarse a la cadena de producción o volver al medio ambiente con el menor impacto posible (Ellen MacArthur Foundation, 2017). Dentro de los retos que debe afrontar la implementación de la EC es la gestión de los residuos, en el contexto Colombiano la Resolución 1407 de 2018 establece directrices para la responsabilidad extendida del productor en envases y empaques, dentro de la cual se define la conformación de redes e iniciativas que contribuyan al cumplimiento de las metas trazadas y el aporte realizado por cada uno de los productores. Teniendo en cuenta lo anterior, la correcta detección y clasificación de envases haciendo uso de Machine Learning dentro de los centros de acopio de residuos puede permitir hacer control de la cantidad de envases que entran al sistema, y por tanto una eficiente trazabilidad de estos.

2. Objetivo de machine learning

En este proyecto se busca entrenar y probar modelos de detección de objetos que puedan identificar botellas de plástico en escenarios del mundo real.

La detección de objetos se asimila al concepto de localización de objetos, con la excepción de que se tiene un número variable de objetos de diferentes clases en la imagen. El objetivo de la detección es identificar todas las instancias de varios objetos (por ejemplo, personas, autos, señales, caras, etc) en una imagen o video (Aggarwal 2018). Generalmente, en la imagen, solo se encuentran presentes un pequeño número de instancias del objeto, pero existen muchas posibles ubicaciones y escalas en las que pueden aparecer y que deben ser exploradas de alguna manera. Cada detección se informa con algún tipo de información de posición. Esto podría ser tan simple como la ubicación del objeto, una localización y escala, o la extensión del objeto definida en términos de un cuadro delimitador. En otras situaciones, la información de posición es más detallada y contiene los parámetros de una transformación lineal o no lineal (Amit y Felzenszwalb 2014).

Figura 1. Explicación visual de la diferencia entre la detección y otros términos que describen la tarea general de ubicar uno o más objetos en una imagen.



Tomado de: (Michelucci 2019)

3. Dataset

Nombre del Dataset: Plastic Bottles in the wild Image Dataset.
Características del Dataset:

- **Tipo de datos:** Imágenes anotadas.
- **Tamaño en disco:** 1.71 GB.
- **Clase única:** Botellas de plástico

El conjunto de datos incluye alrededor de 8,000 datos entre imágenes de botellas de plástico y sus anotaciones, las cuales se encuentran en diversos escenarios exteriores, las anotaciones fueron realizadas en formato de caja delimitadora YOLO. Diseñado así para entrenar y probar modelos de detección de objetos que identifiquen botellas de plástico en situaciones reales. Las imágenes muestran botellas en paisajes naturales y entornos urbanos, algunas veces parcialmente ocultas. Esta variabilidad hace que el conjunto de datos sea desafiante y útil para investigadores en detección de objetos. Está dividido en tres partes: entrenamiento (70%), prueba (20%) y validación (10%).

4. Métricas de desempeño

Las métricas de desempeño que se pueden identificar desde la implementación del modelo de detección son:

- **Error de detección:** En el contexto del modelo propuesto, se puede presentar errores en la detección de los envases en las imágenes, estos pueden ser de tipo “falso positivo” o “falso negativo”. En el primer caso, el modelo detectaría una botella de plástico que no se encuentra en la imagen, y en el segundo caso, el modelo no detectaría la botella de plástico que se encuentra en la imagen.
- **Overfitting(Sobreajuste):** En este caso se debe verificar qué tanto se ajusta el modelo a los datos de entrenamiento, y cómo es el rendimiento con datos de prueba o validación.

Por otro lado, teniendo en cuenta la problemática que se plantea abordar, el sistema estaría ubicado en una banda transportadora de un centro de acopio, este último se encarga del procesamiento de los residuos de envases de todo tipo. En la parte superior de la banda transportadora se ubicaría el sistema que tomaría fotos del material y haría la detección de los envases de acuerdo a las características de los productores, y luego se redistribuiría cada tipo de envase en una línea específica de la banda. Las métricas de desempeño que se pueden establecer en el contexto de negocio son las siguientes:

- **Tasa de error tolerable en la detección:** Se estima una tasa del 10% de error en la detección ya que es el mínimo de material que el centro de acopio estaría dispuesto a no detectar para que no se presenten pérdidas económicas, y poder responder con lo solicitado por los productores.

5. Referencias y resultados previos

Algunos de los estudios que utilizan modelos Deep Learning en el contexto del problema abordado en este proyecto son:

El zaar et al. (2022) buscan identificar la textura y los objetos de plástico en imágenes para reducir los residuos plásticos en los océanos. Para esto, utilizan dos estrategias de transferencia de aprendizaje: la primera utiliza un modelo de red neuronal convolucional (CNN) pre-entrenado en ImageNet como extractor de características, seguido de un clasificador SVM. La segunda estrategia se basa en el ajuste fino del modelo CNN pre-entrenado. El enfoque se probó en dos conjuntos: uno para el reconocimiento de texturas y otro para la detección de objetos. Los resultados fueron muy satisfactorios utilizando ambas estrategias de aprendizaje profundo.

Godoy et al. (2023) presentan un enfoque para detectar diferentes tipos de residuos plásticos reciclables que llegan a una planta de reciclaje utilizando un sistema de inteligencia artificial. Evalúan seis modelos de CNN para esta tarea encontrando que YOLOv5 logra los mejores resultados. Los resultados preliminares muestran una confianza de hasta el 65% en imágenes tomadas de la planta de reciclaje en la ciudad de Posadas, Misiones (Argentina).

Kylili, Hadjistassou, y Artusi (2020) proponen una red neuronal convolucional (CNN) que utiliza el método del cuello de botella (BM) para crear un clasificador de imágenes que permita discernir plásticos marinos en la costa y en el mar. Se examinaron dos escenarios en este estudio, que midieron el rendimiento de la técnica. Inicialmente, el primer escenario examinó la variación en el número de épocas, mientras que el segundo escenario varió el tamaño del lote. Los resultados de los dos escenarios demostraron que el clasificador de imágenes BM con 50 épocas y un tamaño de lote de 5 logró la mayor precisión de validación, que fue del 90%.

Finalmente, Narayanan et al. (2020) buscan perfilar los residuos plásticos que se generan en la India mediante el procesamiento de imágenes y la detección de objetos. Los autores eligieron un modelo Faster R-CNN con ResNet101 (faster_rcnn_resnet101_coco). El entrenamiento del modelo se realizó con el 85% del conjunto de datos total. Otro 10% se utilizó para pruebas y el 5% de los datos se utilizó para validar los resultados.

Referencias

- Aggarwal, Charu C. 2018. "Convolutional Neural Networks". *Neural Networks and Deep Learning* 315–71.
- Amit, Yali, y Pedro Felzenszwalb. 2014. "Object Detection". *Computer Vision* 537–42.
- Ellen MacArthur Foundation. (2017). What Is The Circular Economy? Recuperado de <https://www.ellenmacarthurfoundation.org/circular-economy/what-is-the-circular-economy>
- Godoy, Diego Alberto, Enrique Marcelo Albornoz, Ricardo Selva, Nicolas Ibarra, y Cesar Gallardo. 2023. "Classification of Polyethylene Terephthalate Bottles in a Recycling Plant". *Communications in Computer and Information Science* 1706 CCIS:173–84.
- Kirchherr, J., Reike, D., & Hekkert, M. (2017). Conceptualizing the circular economy: An analysis of 114 definitions. *Resources, Conservation and Recycling*, 127(September), 221–232. <https://doi.org/10.1016/j.resconrec.2017.09.005>
- Kylili, Kyriaki, Constantinos Hadjistassou, y Alessandro Artusi. 2020. "An intelligent way for discerning plastics at the shorelines and the seas". *Environmental Science and Pollution Research* 27(34):42631–43.
- Michelucci, Umberto. 2019. "Object Classification: An Introduction". *Advanced Applied Deep Learning* 195–220.
- Narayanan, Mahadevan, Apurva Mhatre, Ajun Nair, Akilesh Panicker, y Ashutosh Dhondkar. 2020. "Plastic waste profiling using deep learning". *Advances in Intelligent Systems and Computing* 1108 AISC:294–303.
- El zaar, Abdellah, Ayoub Aoulalay, Nabil Benaya, Abderrahim El mhouti, Mohammed Massar, y Abderrahim El allati. 2022. "A Deep Learning Approach to Manage and Reduce Plastic Waste in the Oceans". *E3S Web of Conferences* 336:00065.
- Siddharth Sah. (2023). Plastic Bottles in the wild Image Dataset. <https://www.kaggle.com/datasets/siddharthkumarsah/plastic-bottles-image-dataset>